

Réplica de DeepAR sobre el Dataset M5 Forecasting

Caso California: Pronóstico Probabilístico de Ventas con
Redes Recurrentes Autoregresivas

Trabajo de Forecasting con Aprendizaje Profundo

1 de junio de 2026

Índice

1. Introducción	3
2. Objetivo	3
3. Descripción del Dataset	4
3.1. M5 Forecasting Challenge	4
3.2. Subconjunto California	4
3.3. Covariables estáticas	4
4. Análisis Exploratorio	5
4.1. Distribución de ventas	5
4.2. Proporción de ceros	5
4.3. Estadísticos descriptivos	6
4.4. Implicaciones para el modelado	6
5. Tratamiento de Datos	7
5.1. Estructura matricial	7
5.2. Covariables temporales	7
5.3. Normalización de covariables	7
6. Arquitectura del Modelo	8
6.1. DeepAR: descripción teórica	8
6.2. Distribución de salida: Binomial Negativa	8
6.3. Configuración experimental	9
6.4. Infraestructura de entrenamiento	9
7. Resultados	10
7.1. Comparación de modelos	10
7.2. Análisis de métricas	10

8. Evaluación Probabilística	11
8.1. Pérdida cuantílica	11
8.2. Análisis de cobertura	12
9. Diagnóstico de Predicciones Extremas	12
9.1. Problema inicial	12
9.2. Resultados tras la corrección	12
9.3. Subestimación en la cola	13
10.Discusión	13
11.Limitaciones	14
12.Trabajo Futuro	14
13.Conclusiones	15

1. Introducción

El pronóstico de series de tiempo es uno de los problemas centrales en el análisis de demanda minorista. Los métodos clásicos — como ARIMA, suavizamiento exponencial o regresiones lineales — modelan cada serie de forma independiente, lo cual ignora la estructura latente compartida entre productos de un mismo retailer. En contextos como el M5 Forecasting Challenge, donde se dispone de decenas de miles de series relacionadas, este enfoque local es ineficiente.

DeepAR [Salinas et al., 2020] es un modelo de pronóstico probabilístico desarrollado por Amazon Research. Su contribución principal es el entrenamiento de un único modelo global sobre un panel de series de tiempo relacionadas, aprovechando transferencia de información entre ellas mediante una red recurrente (LSTM o GRU). A diferencia de los métodos puntuales, DeepAR estima una *distribución* de probabilidad sobre el futuro, lo que permite cuantificar la incertidumbre de manera explícita.

El presente proyecto replica la idea central de DeepAR sobre el **subconjunto California** del dataset M5 Forecasting [Makridakis et al., 2022], compuesto por 12 196 series producto-tienda y 1913 días históricos de ventas. El objetivo es evaluar si un modelo global probabilístico supera a benchmarks simples — valor último, seasonal naive y promedio móvil — en un horizonte de predicción de 28 días.

El documento está organizado de la siguiente manera: la Sección 2 formaliza el objetivo; la Sección 3 describe los datos; la Sección 4 presenta el análisis exploratorio; la Sección 5 describe el tratamiento de datos; la Sección 6 explica la arquitectura del modelo; la Sección 7 reporta los resultados cuantitativos; la Sección 8 analiza la evaluación probabilística; la Sección 9 discute el diagnóstico de predicciones extremas; y las Secciones 10–13 presentan la discusión, limitaciones, trabajo futuro y conclusiones.

2. Objetivo

El objetivo principal es entrenar un modelo DeepAR para pronosticar las ventas diarias de productos en tiendas de California durante un horizonte de $h = 28$ días.

Formalmente, el modelo busca estimar la distribución conjunta condicional:

$$P(y_{t_0:t_0+h} \mid y_{1:t_0-1}, \mathbf{x}_{1:t_0+h}) \quad (1)$$

donde:

- $y_t \in \mathbb{Z}_{\geq 0}$ representa las ventas diarias de un producto en una tienda particular;
- $\mathbf{x}_t$ es el vector de covariables conocidas en el tiempo t (variables de calendario, identificadores de producto/tienda, indicadores de SNAP);
- $h = 28$ es el horizonte de predicción.

Adicionalmente, se comparó DeepAR contra tres modelos base de referencia:

1. **Naive último valor:** $\hat{y}_{t+k} = y_t$ para $k = 1, \dots, h$.

2. **Seasonal Naive de 28 días:** $\hat{y}_{t+k} = y_{t+k-28}$.
3. **Promedio móvil de 28 días:** $\hat{y}_{t+k} = \frac{1}{28} \sum_{j=0}^{27} y_{t-j}$.

3. Descripción del Dataset

3.1. M5 Forecasting Challenge

El dataset M5 fue publicado para la quinta edición de la competencia de pronóstico Makridakis [Makridakis et al., 2022]. Contiene ventas históricas diarias de productos de Walmart en tres estados de Estados Unidos (California, Texas y Wisconsin), abarcando distintas categorías (alimentos, hogar y aficionados).

3.2. Subconjunto California

En este proyecto se trabajó exclusivamente con el estado de California. Este subconjunto contiene:

Cuadro 1: Características del subconjunto M5 California.

Característica	Valor
Series producto-tienda	12 196
Productos distintos	3 049
Departamentos	7
Categorías	3
Tiendas	4
Estado	California
Días históricos	1 913

3.3. Covariables estáticas

Las covariables estáticas utilizadas como identificadores de cada serie fueron:

Cuadro 2: Covariables estáticas y sus cardinalidades.

Variable	Cardinalidad
item_id	3 049
dept_id	7
cat_id	3
store_id	4
state_id	1

Estas variables son codificadas como embeddings aprendibles dentro del modelo DeepAR, permitiendo que el modelo diferencie el comportamiento de distintos productos, categorías y tiendas sin requerir one-hot encoding de alta dimensión.

4. Análisis Exploratorio

4.1. Distribución de ventas

El análisis inicial reveló que las ventas tienen una distribución *altamente sesgada hacia la derecha*. La mayoría de las series reportan ventas promedio bajas, mientras que pocas series concentran niveles elevados de demanda.




Figura 1: Distribución de $\log(1 + \text{ventas promedio})$ por serie. La concentración en valores bajos y la cola derecha confirman la alta heterogeneidad entre series.

4.2. Proporción de ceros

Una característica fundamental del dataset es la alta presencia de ceros, característica de series con *demandas intermitentes*. La media del porcentaje de ceros por serie fue de aproximadamente 66,2%.




Figura 2: Distribución del porcentaje de ceros por serie. La mayoría de las series presenta ventas cero durante más del 50 % del período histórico.

4.3. Estadísticos descriptivos

Cuadro 3: Estadísticos descriptivos de las 12 196 series de California.

Métrica	total_sales	mean_sales	zero_ratio
count	12 196	12 196	12 196
mean	2 351.23	1.23	0.662
std	5 481.93	2.87	0.231
min	10	0.005	0.002
25 %	400.75	0.209	0.502
50 %	974	0.509	0.710
75 %	2 286.25	1.195	0.856
max	250 502	130.947	0.996

4.4. Implicaciones para el modelado

Los hallazgos del análisis exploratorio tienen implicaciones directas sobre la elección del modelo:

1. La **alta heterogeneidad** entre series justifica el uso de un modelo global que aprenda representaciones compartidas.
2. La **demanda intermitente** (66 % de ceros) descarta distribuciones continuas como la Normal o la Log-Normal.
3. La **sobredispersión** (varianza $\gg$ media en muchas series) hace preferible la **Binomial Negativa** sobre la Poisson, ya que la Poisson supone varianza = media.
4. La **cola derecha larga** señala que el modelo debe gestionar bien los cuantiles superiores para no subestimar la demanda de productos populares.

5. Tratamiento de Datos

5.1. Estructura matricial

Para evitar problemas de memoria RAM — cargar 12 196 series en formato largo generaría un DataFrame de aproximadamente 23×10^6 filas — se optó por mantener los datos en formato matricial compacto:

$$\mathbf{Y} \in \mathbb{R}^{N \times T}, \quad N = 12\,196, \quad T = 1\,913 \quad (2)$$

Se definió un horizonte de validación de 28 días, lo que generó las siguientes particiones:

Cuadro 4: Partición entrenamiento/validación.

Conjunto	Días	Dimensiones de $\mathbf{Y}$
Entrenamiento	1 885	(12 196, 1 885)
Validación	1 913	(12 196, 1 913)

La evaluación se realizó sobre los últimos 28 días, comparando las predicciones del modelo contra los valores reales del conjunto de validación.

5.2. Covariables temporales

Las covariables temporales utilizadas como entradas al modelo fueron:

- **Día de la semana** (0–6): captura estacionalidad semanal.
- **Día del mes** (1–31): captura efectos de inicio/fin de mes.
- **Semana del año** (1–53): captura estacionalidad anual.
- **Mes** (1–12): captura efectos mensuales.
- **SNAP California**: indicador binario de días en que el programa SNAP permite compras con beneficios gubernamentales, el cual tiene un efecto documentado sobre la demanda de alimentos.

5.3. Normalización de covariables

Un problema detectado durante el desarrollo fue que, al codificar las covariables temporales como enteros sin normalizar (por ejemplo, día del año 1–365), el modelo generaba predicciones extremas del orden de 10^3 – 10^5 unidades. Esto ocurre porque la red recurrente interpreta los valores enteros grandes como señales de magnitud, distorsionando la escala de las activaciones internas.

La solución fue normalizar todas las covariables temporales al rango $[0, 1]$ mediante:

$$\tilde{x} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (3)$$

Tras esta corrección, las predicciones se estabilizaron en rangos razonables y acordes con los valores históricos observados.

6. Arquitectura del Modelo

6.1. DeepAR: descripción teórica

DeepAR [Salinas et al., 2020] modela la distribución predictiva de forma *autoregresiva*, factorizando la distribución conjunta como:

$$P(y_{t_0:T} \mid y_{1:t_0-1}, \mathbf{x}_{1:T}) = \prod_{t=t_0}^T P(y_t \mid y_{1:t-1}, \mathbf{x}_{1:T}) \quad (4)$$

En cada paso temporal t , la red recurrente (LSTM) recibe como entrada el valor observado $z_{i,t-1}$ (o muestras de la distribución predictiva durante la fase de generación) y el vector de covariables $\mathbf{x}_{i,t}$. El estado oculto resultante $\mathbf{h}_{i,t}$ es proyectado a los parámetros de la distribución de salida elegida:

$$\mathbf{h}_{i,t} = \text{LSTM}(\mathbf{h}_{i,t-1}, [z_{i,t-1}, \mathbf{x}_{i,t}, \mathbf{e}_i]) \quad (5)$$

donde $\mathbf{e}_i$ es el embedding estático de la serie i , que encapsula características fijas como categoría, tienda y producto.

6.2. Distribución de salida: Binomial Negativa

La distribución de salida elegida fue la **Binomial Negativa**, parametrizada por su media μ y el parámetro de dispersión α (o equivalentemente $r = 1/\alpha$):

$$P(Y = k \mid \mu, \alpha) = \frac{\Gamma(k + 1/\alpha)}{\Gamma(1/\alpha) k!} \left(\frac{1/\alpha}{1/\alpha + \mu} \right)^{1/\alpha} \left(\frac{\mu}{1/\alpha + \mu} \right)^k, \quad k \in \mathbb{Z}_{\geq 0} \quad (6)$$

La media y la varianza de esta distribución son:

$$\mathbb{E}[Y] = \mu \quad (7)$$

$$\text{Var}[Y] = \mu + \alpha \mu^2 \quad (8)$$

La Binomial Negativa es adecuada porque:

1. Genera valores enteros no negativos, consistentes con datos de conteo de ventas.
2. Permite varianza $>$ media (sobredispersión), lo cual es común en demanda minorista.
3. Maneja apropiadamente la presencia de ceros como parte natural de la distribución.

6.3. Configuración experimental

La configuración final del modelo fue:

```
DeepAREstimator(  
    freq                = "D",  
    prediction_length    = 28,  
    context_length       = 84,      # 3 x prediction_length  
    num_layers           = 3,  
    hidden_size          = 80,  
    dropout_rate         = 0.1,  
    distr_output         = NegativeBinomialOutput(),  
    batch_size           = 128,  
    num_batches_per_epoch = 300,  
    lr                   = 5e-4,  
    max_epochs           = 40  
)
```

Listing 1: Configuración del estimador DeepAR.

Algunos aspectos a destacar de esta configuración:

- **context_length = 84**: el modelo observa 84 días de historia (3 veces el horizonte de predicción) para generar el pronóstico. Esto permite capturar estacionalidad semanal (ciclos de 7 días) en múltiples semanas.
- **num_layers = 3**: tres capas LSTM apiladas permiten representar patrones jerárquicos en la serie temporal.
- **dropout_rate = 0.1**: regularización para reducir sobreajuste dado el tamaño del modelo.
- **lr = 5e-4**: tasa de aprendizaje con optimizador Adam.

6.4. Infraestructura de entrenamiento

El entrenamiento se realizó en **Google Colab** usando GPU NVIDIA T4. El tiempo aproximado de entrenamiento fue de **31 minutos** para 40 épocas sobre las 12 196 series.

Durante el entrenamiento, el modelo optimiza la log-verosimilitud negativa de la distribución de salida:

$$\mathcal{L}(\theta) = - \sum_{i=1}^N \sum_{t \in \Omega_{\text{train}}} \log P_{\theta}(y_{i,t} \mid y_{i,1:t-1}, \mathbf{x}_{i,1:t}) \quad (9)$$

donde Ω_{train} denota el conjunto de pasos temporales de entrenamiento.

7. Resultados

7.1. Comparación de modelos

La Tabla 5 muestra el desempeño comparativo de los cuatro modelos evaluados sobre el conjunto de validación (últimos 28 días de cada serie).

Cuadro 5: Comparación de modelos: métricas de error en el conjunto de validación.

Modelo	MAE	RMSE	sMAPE	Bias
Naive último valor	1.4794	3.4521	0.8541	0.2698
Seasonal Naive 28 días	1.3416	2.9028	0.8428	-0.0286
Moving Average 28 días	1.1070	2.2604	1.2616	-0.0286
DeepAR Neg. Binomial	0.9950	2.2279	0.7032	-0.4239

7.2. Análisis de métricas

MAE (Mean Absolute Error): DeepAR obtuvo un MAE de 0,9950, reduciéndolo en un 10,1 % respecto al mejor baseline (Moving Average, 1,1070). Dado que la venta media es 1,23 unidades, esta mejora es relevante en términos relativos.

RMSE (Root Mean Squared Error): DeepAR logró el RMSE más bajo (2,2279), aunque la diferencia respecto al Moving Average (2,2604) es modesta. El RMSE penaliza más los errores grandes, y el promedio móvil es un benchmark competitivo para series con comportamiento estable.

sMAPE (Symmetric Mean Absolute Percentage Error): DeepAR obtuvo el sMAPE más bajo (0,7032), superando significativamente al Moving Average (1,2616). El sMAPE alto del promedio móvil se explica porque, en series con ventas cercanas a cero, pequeños errores absolutos generan grandes errores porcentuales.

Bias: El bias de DeepAR fue $-0,4239$, indicando una leve *subestimación sistemática* de la demanda. Los modelos Seasonal Naive y Moving Average presentan un bias cercano a cero, mientras que el Naive último valor tiene bias positivo (sobreestimación).




Figura 3: Comparación de modelos según RMSE. DeepAR obtiene el RMSE más bajo, aunque la diferencia con el promedio móvil de 28 días es moderada.

8. Evaluación Probabilística

Una ventaja clave de DeepAR sobre los modelos base es su capacidad de generar *distribuciones predictivas* en lugar de únicamente predicciones puntuales. A partir de muestras de la distribución posterior, se calcularon cuantiles e intervalos de predicción.

8.1. Pérdida cuantílica

La pérdida cuantílica (*Quantile Loss*, QL) para el nivel q se define como:

$$QL_q = \frac{2}{n} \sum_{i=1}^n [q \cdot \max(y_i - \hat{q}_i, 0) + (1 - q) \cdot \max(\hat{q}_i - y_i, 0)] \quad (10)$$

Cuadro 6: Métricas probabilísticas de DeepAR.

Métrica	Valor
QL 0.5 (mediana)	0.4975
QL 0.9 (cuantil superior)	0.3334
Cobertura intervalo 80 %	0.9090

8.2. Análisis de cobertura

La cobertura del intervalo del 80 % fue de **90.9 %**, superando el nivel nominal del 80 %. Esto indica que el modelo es *conservador*: sus intervalos de predicción son más amplios de lo óptimo, capturando más observaciones reales que las esperadas.

La sobrecobertura puede deberse a:

1. El parámetro de dispersión α de la Binomial Negativa puede estar sobreestimando la variabilidad de las series.
2. El modelo no está perfectamente calibrado respecto a la distribución empírica.
3. La heterogeneidad entre series hace difícil calibrar un único modelo global para todos los niveles de demanda.




Figura 4: Pronóstico probabilístico para una serie de alta demanda. La línea azul muestra la historia real, la línea naranja el forecast y el área sombreada el intervalo predictivo al 80 %. El modelo captura la dinámica general aunque tiende a suavizar los picos de demanda.

9. Diagnóstico de Predicciones Extremas

9.1. Problema inicial

Durante el desarrollo, una versión preliminar del modelo generaba predicciones extremas del orden de 10^3 – 10^5 unidades, claramente inconsistentes con el rango histórico. La causa raíz fue el tratamiento incorrecto de las covariables temporales: al codificarlas como enteros sin normalizar, la red interpretaba valores como “día 300” o “día 1913” como señales de gran magnitud, distorsionando las activaciones de la LSTM.

9.2. Resultados tras la corrección

Después de normalizar las covariables temporales al rango $[0, 1]$, las predicciones se estabilizaron. La Tabla 7 muestra los valores máximos comparativos:

Cuadro 7: Valores extremos: predicción vs. real.

Métrica	Valor
Predicción máxima DeepAR	150
Real máximo	204
Error absoluto máximo	102

Cuadro 8: Distribución de percentiles: predicción DeepAR vs. valores reales.

Percentil	Predicción DeepAR	Real
50 %	0	0
75 %	1	2
90 %	3	4
95 %	4	6
99 %	11	15
99.5 %	15	21
99.9 %	31	41
100 %	150	204

9.3. Subestimación en la cola

La Tabla 8 muestra un patrón consistente: a partir del percentil 75, las predicciones de DeepAR son sistemáticamente menores que los valores reales. En el percentil 99.9, el modelo predice 31 unidades mientras que la demanda real fue de 41 (una subestimación del $\sim 24\%$). Esto refleja que el modelo aprende bien el comportamiento típico de las series, pero tiende a truncar la cola superior de la distribución.

Esta característica es habitual en modelos globales entrenados con muchas series de demanda baja: la función de pérdida penaliza igualmente todos los errores, por lo que el modelo tiende a optimizar el desempeño en la masa central de la distribución, a costa de los cuantiles extremos.

10. Discusión

Los resultados obtenidos son satisfactorios para una primera réplica de DeepAR sobre M5 California. El modelo superó a los tres benchmarks en MAE y sMAPE, y obtuvo el RMSE más bajo, aunque la diferencia con el promedio móvil de 28 días es moderada.

Ventajas del enfoque global. DeepAR aprovecha la transferencia de información entre las 12 196 series. Esto es especialmente valioso para series con demanda intermitente, donde el historial individual es poco informativo. El modelo puede aprender, por ejemplo, que los patrones de venta de un producto nuevo en una tienda son similares a los de productos similares en otras tiendas.

Limitación: subestimación del bias. El bias negativo ($-0,4239$) indica una subestimación sistemática. Esto puede corregirse mediante:

- Ajuste del umbral de predicción (predicción condicional en cuantiles superiores).
- Incorporación de precios y eventos como covariables, que son predictores de picos de demanda.
- Post-procesamiento de las predicciones mediante escalado por factor de corrección de bias.

Limitación: intervalos conservadores. La cobertura del 90.9 % para un intervalo nominal del 80 % indica que los intervalos son demasiado amplios. Esto reduce la utilidad práctica del modelo para gestión de inventario, donde intervalos muy amplios impiden decisiones de stock precisas. Se recomienda aplicar calibración de cuantiles post-entrenamiento, como *conformal prediction* o escalado de temperatura.

11. Limitaciones

Las principales limitaciones del presente proyecto son:

1. **Subconjunto geográfico:** se trabajó únicamente con California y no con el dataset M5 completo (tres estados). Esto reduce la generalización del modelo y no permite comparación directa con los resultados oficiales de la competencia.
2. **Sin covariables de precio:** el campo `sell_price` no fue incorporado como covariable dinámica, lo cual es una omisión importante dado el efecto de las promociones y descuentos sobre la demanda.
3. **Sin eventos del calendario:** los eventos especiales (festivos nacionales, fiestas deportivas, eventos locales) no se incorporaron en esta versión. Estos eventos tienen impacto documentado en las ventas de retail.
4. **Métrica de evaluación:** no se evaluó con WRMSSE (*Weighted Root Mean Squared Scaled Error*), que es la métrica oficial de M5 y pondera la importancia de cada serie según su volumen de ventas.
5. **Subestimación en alta demanda:** el modelo presenta una tendencia a subestimar la demanda en productos con ventas elevadas o picos importantes.
6. **Intervalos probabilísticos conservadores:** los intervalos predictivos cubren más del nivel nominal, reduciendo su utilidad operativa.

12. Trabajo Futuro

Para mejorar y extender el modelo se recomienda:

1. **Incorporar precios:** incluir `sell_price` como covariable dinámica, posiblemente junto con indicadores de descuento o variación de precio respecto a la semana anterior.

2. **Agregar eventos y promociones:** codificar los eventos del calendario M5 (“SNAP”, festivos, eventos deportivos) como variables binarias o embeddings categóricos.
3. **Entrenar sobre todo M5:** extender el entrenamiento a los tres estados para aprovechar mejor la capacidad de generalización del modelo global y permitir comparación con la literatura.
4. **Comparar contra modelos más fuertes:** evaluar LightGBM con features de lagged values, N-BEATS [Oreshkin et al., 2020] y Temporal Fusion Transformer [Lim et al., 2021], que son los modelos de mejor desempeño en M5.
5. **Evaluar con WRMSSE:** implementar la métrica oficial de M5 para obtener resultados comparables con los reportados en la competencia.
6. **Explorar contextos temporales más largos:** probar `context_length` de 112 o 168 días para capturar ciclos de 4 y 6 semanas respectivamente.
7. **Calibración probabilística:** aplicar técnicas de calibración de cuantiles post-entrenamiento (por ejemplo, *conformal prediction*) para reducir la amplitud excesiva de los intervalos predictivos.

13. Conclusiones

En este proyecto se replicó exitosamente la idea central de DeepAR [Salinas et al., 2020] sobre el subconjunto California del dataset M5 Forecasting.

Los principales hallazgos son:

1. **DeepAR superó a los tres benchmarks** en MAE (0.9950 vs. 1.1070), RMSE (2.2279 vs. 2.2604) y sMAPE (0.7032 vs. 0.8428). Esto confirma que el entrenamiento global sobre múltiples series relacionadas aporta valor frente a métodos simples de forecasting.
2. **La distribución Binomial Negativa** fue una elección adecuada para los datos de M5, dados los altos porcentajes de ceros ($\sim 66\%$) y la fuerte sobredispersión observadas en el análisis exploratorio.
3. **La normalización de covariables temporales** fue un punto crítico del desarrollo. Sin normalización, el modelo generaba predicciones absurdas. Con normalización al rango $[0, 1]$, las predicciones se estabilizaron de inmediato, resaltando la importancia del preprocesamiento en modelos de aprendizaje profundo.
4. **La evaluación probabilística** mostró que DeepAR genera intervalos conservadores (cobertura 90.9 % para nivel nominal 80 %), lo que indica espacio de mejora en la calibración de la distribución predictiva.
5. **Existe subestimación en la cola superior**, donde el modelo predice consistentemente menos que los valores reales en los percentiles 75–99.9. Esto es un efecto típico de modelos globales entrenados con mayoría de series de demanda baja.

A pesar de estas limitaciones, los resultados obtenidos constituyen una base sólida para futuras iteraciones. Las mejoras más prometedoras involucran la incorporación de precios

y eventos del calendario como covariables, la calibración de cuantiles post-entrenamiento y la evaluación formal con la métrica WRMSSE sobre el dataset M5 completo.

Referencias

- Salinas, D., Flunkert, V., Gasthaus, J., & Januschowski, T. (2020). DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks. *International Journal of Forecasting*, 36(3), 1181–1191. <https://doi.org/10.1016/j.ijforecast.2019.07.001>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 Accuracy Competition: Results, Findings, and Conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>
- Oreshkin, B. N., Carпов, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/1905.10437>
- Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting. *International Journal of Forecasting*, 37(4), 1748–1764. <https://doi.org/10.1016/j.ijforecast.2021.03.012>