

Réplica de DeepAR sobre el Dataset M5 Forecasting

Caso California: Pronóstico Probabilístico de Ventas con
Redes Recurrentes Autoregresivas

Trabajo de Forecasting con Aprendizaje Profundo

2 de junio de 2026

Índice

1. Introducción	3
2. Objetivo	3
3. Descripción del Dataset	4
3.1. M5 Forecasting Challenge	4
3.2. Subconjunto California	4
3.3. Covariables estáticas	4
4. Análisis Exploratorio	5
4.1. Distribución de ventas	5
4.2. Proporción de ceros	5
4.3. Estadísticos descriptivos	6
4.4. Implicaciones para el modelado	6
5. Tratamiento de Datos	7
5.1. Estructura matricial	7
5.2. Covariables temporales	7
5.3. Normalización de covariables	8
6. Arquitectura del Modelo	8
6.1. DeepAR: descripción teórica	8
6.2. Distribución de salida: Binomial Negativa	9
6.3. Configuración experimental	9
6.4. Infraestructura de entrenamiento	10
7. Resultados	10
7.1. Comparación de modelos	10
7.2. Análisis de métricas	11

8. Evaluación Probabilística	12
8.1. Pérdida cuantílica	12
8.2. Análisis de cobertura	13
9. Diagnóstico de Predicciones Extremas	13
9.1. Problema inicial	13
9.2. Resultados tras la corrección	13
9.3. Subestimación en la cola	14
10.Discusión	14
11.Limitaciones	15
12.Trabajo Futuro	15
13.Conclusiones	16
14.Análisis de Resultados y Conclusiones	17

1. Introducción

En el panorama actual, para la industria dedicada a la cadena de suministro, el pronóstico de series de tiempo es una de sus problemáticas principales. Dentro del machine learning, los métodos tradicionales en el área como ARIMA, suavizamiento exponencial o regresiones lineales se centran en modelar cada serie de forma independiente, lo cual ignora la estructura latente que comparten ciertos productos dentro de una tienda retail. En problemas como el M5 Forecasting Challenge, donde existen miles de series que están correlacionadas, el enfoque tradicional es deficiente.

DeepAR [Salinas et al., 2020] es un modelo de pronóstico probabilístico desarrollado por Amazon. Su contribución o innovación principal en contraste a los modelos tradicionales es el entrenamiento de un único modelo global sobre diferentes series de tiempo que están relacionadas, aprovechando la información compartida entre ellas mediante una red recurrente (LSTM). A diferencia de los otros métodos, DeepAR estima una *distribución de probabilidad* sobre el futuro, donde el mayor beneficio es cuantificar la incertidumbre de manera explícita.

El presente proyecto replica la idea central de DeepAR sobre el **subconjunto California** del dataset M5 Forecasting [Makridakis et al., 2022], compuesto por 12 196 series producto-tienda y 1913 días históricos de ventas. El objetivo del paper es evaluar si un modelo global probabilístico supera a benchmarks simples(el valor anterior mas reciente, el mismo comportamiento de los últimos 28 días y promedio móvil) en un horizonte de predicción de 28 días.

El documento está organizado de la siguiente manera: la Sección 2 formaliza el objetivo; la Sección 3 describe los datos; la Sección 4 presenta el análisis exploratorio; la Sección 5 describe el tratamiento de datos; la Sección 6 explica la arquitectura del modelo; la Sección 7 reporta los resultados cuantitativos; la Sección 8 analiza la evaluación probabilística; la Sección 9 discute el diagnóstico de predicciones extremas; y las Secciones 10–13 presentan la discusión, limitaciones, trabajo futuro y conclusiones.

2. Objetivo

El objetivo principal es entrenar el modelo propuesto por Amazon: DeepAR para pronosticar el intervalo de ventas diarias de productos en tiendas de California durante un horizonte de $h = 28$ días.

Formalmente, el modelo busca estimar la distribución conjunta condicional:

$$P(y_{t_0:t_0+h} \mid y_{1:t_0-1}, \mathbf{x}_{1:t_0+h}) \quad (1)$$

donde:

- $y_t \in \mathbb{Z}_{\geq 0}$ representa las ventas diarias de un producto en una tienda particular;
- $\mathbf{x}_t$ es el vector de covariables conocidas en el tiempo t (variables de calendario, identificadores de producto/tienda, indicadores de SNAP);

- $h = 28$ es el horizonte de predicción.

Adicionalmente, se comparó DeepAR contra tres modelos base de referencia:

1. **Naive último valor:** $\hat{y}_{t+k} = y_t$ para $k = 1, \dots, h$.
2. **Seasonal Naive de 28 días:** $\hat{y}_{t+k} = y_{t+k-28}$.
3. **Promedio móvil de 28 días:** $\hat{y}_{t+k} = \frac{1}{28} \sum_{j=0}^{27} y_{t-j}$.

3. Descripción del Dataset

3.1. M5 Forecasting Challenge

El dataset M5 fue publicado para la quinta edición de la competencia de pronóstico Makridakis [Makridakis et al., 2022]. Este documento contiene ventas históricas diarias de productos de la empresa Walmart en tres estados diferentes de Estados Unidos (California, Texas y Wisconsin), abarcando distintas categorías de productos (alimentos, hogar y aficionados).

3.2. Subconjunto California

En este proyecto, por limitaciones computacionales comparadas con el paper original, se trabajó exclusivamente acotando nuestro universo a solo los registros dentro del estado de California. Este subconjunto contiene:

Cuadro 1: Características del subconjunto M5 California.

Característica	Valor
Series producto-tienda	12 196
Productos distintos	3 049
Departamentos	7
Categorías	3
Tiendas	4
Estado	California
Días históricos	1 913

3.3. Covariables estáticas

Las covariables estáticas utilizadas como identificadores de cada serie fueron:

Cuadro 2: Covariables estáticas.

Variable	Cardinalidad
item_id	3 049
dept_id	7
cat_id	3
store_id	4
state_id	1

Estas variables son codificadas directamente como embeddings aprendibles dentro del modelo DeepAR con el propósito de que el modelo diferencie el comportamiento de distintos productos, categorías y tiendas sin requerir un complejo mapeo con one-hot encoding que conduciría a un aumento de dimensión (el cual evitamos por los recursos computacionales limitados).

4. Análisis Exploratorio

4.1. Distribución de ventas

Un análisis inicial del dataset mostró que las ventas tienen una distribución *altamente sesgada hacia la derecha*. La mayoría de las series reportan ventas consistentemente bajas, mientras que pocas series concentran niveles elevados de demanda.




Figura 1: Distribución de $\log(1 + \text{ventas promedio})$ por serie. La concentración en valores bajos y la cola derecha confirman la alta heterogeneidad entre series.

4.2. Proporción de ceros

Una característica fundamental del dataset es la alta presencia de registros con cero ventas, lo cual es una característica de series con *una demanda intermitente*. La media del porcentaje de ceros por serie fue de aproximadamente 66,2%.




Figura 2: Distribución del porcentaje de ceros por serie. La mayoría de las series presenta ventas cero durante más del 50 % del período histórico.

4.3. Estadísticos descriptivos

Cuadro 3: Estadísticos descriptivos de las 12 196 series de California.

Métrica	total_sales	mean_sales	zero_ratio
count	12 196	12 196	12 196
mean	2 351.23	1.23	0.662
std	5 481.93	2.87	0.231
min	10	0.005	0.002
25 %	400.75	0.209	0.502
50 %	974	0.509	0.710
75 %	2 286.25	1.195	0.856
max	250 502	130.947	0.996

4.4. Implicaciones para el modelado

Los hallazgos del análisis exploratorio inicial del dataset tienen implicaciones directas sobre la posterior elección del modelo:

1. La **alta heterogeneidad** entre series justifica el uso de un modelo global que aprenda representaciones compartidas.
2. La **demanda intermitente** (66 % de ceros) descarta distribuciones continuas como la Normal o la Log-Normal.
3. La **sobredispersión** (varianza $\gg$ media en muchas series) hace preferible la **Binomial Negativa** sobre la Poisson, ya que la Poisson supone varianza = media.
4. La **cola derecha larga** señala que el modelo debe gestionar bien los cuantiles superiores para no subestimar la demanda de ciertos productos similares o constantes.

5. Tratamiento de Datos

5.1. Estructura matricial

Por el tamaño del dataset y las limitaciones ya mencionadas, para evitar problemas de memoria RAM (cargar 12 196 series en formato largo generaría un DataFrame de aproximadamente 23×10^6 filas) se optó por mantener los datos en formato matricial compacto:

$$\mathbf{Y} \in \mathbb{R}^{N \times T}, \quad N = 12\,196, \quad T = 1\,913 \quad (2)$$

Con el fin de robustecer el proceso de ajuste y evaluación del modelo, los datos históricos fueron divididos formalmente en tres particiones secuenciales independientes: un conjunto de **Entrenamiento**, un conjunto de **Validación** (empleado para evaluar la función de pérdida y el comportamiento de la norma L2 de los gradientes), y un conjunto final de **Prueba (Test)** aislado para el reporte definitivo de métricas sobre un horizonte no visto de 28 días. Las particiones se estructuraron de la siguiente manera:

Cuadro 4: Partición secuencial del dataset: entrenamiento, validación y prueba.

Conjunto	Días Históricos	Dimensiones de $\mathbf{Y}$
Entrenamiento	1 857	(12 196, 1 857)
Validación	1 885	(12 196, 1 885)
Prueba (Test)	1 913	(12 196, 1 913)

La evaluación final del rendimiento real del modelo se realizó estrictamente sobre los últimos 28 días correspondientes al conjunto de prueba, comparando las predicciones generadas contra los valores reales guardados.

5.2. Covariables temporales

Las covariables temporales utilizadas como entradas al modelo fueron:

- **Día de la semana** (0–6)
- **Día del mes** (1–31)
- **Semana del año** (1–53)
- **Mes** (1–12)
- **SNAP California**: indicador binario de días en que el programa SNAP permite compras con beneficios gubernamentales, el cual tiene un efecto documentado sobre la demanda de alimentos.

5.3. Normalización de covariables

Un problema detectado durante el desarrollo fue que, al codificar las covariables temporales como enteros sin normalizar (por ejemplo, día del año 1–365), el modelo generaba predicciones extremas del orden de 10^5 unidades. Esto ocurre porque la red recurrente interpreta los valores enteros grandes como señales de magnitud, lo cual distorsiona la escala de las activaciones internas.

La solución fue normalizar todas las covariables temporales al rango $[0, 1]$ mediante:

$$\tilde{x} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (3)$$

Tras esta corrección, las predicciones se estabilizaron en rangos razonables que hacen sentido con los valores históricos observados.

6. Arquitectura del Modelo

6.1. DeepAR: descripción teórica

DeepAR [Salinas et al., 2020] modela la distribución predictiva de forma *autoregresiva*, factorizando la distribución conjunta como:

$$P(y_{t_0:T} \mid y_{1:t_0-1}, \mathbf{x}_{1:T}) = \prod_{t=t_0}^T P(y_t \mid y_{1:t-1}, \mathbf{x}_{1:T}) \quad (4)$$

En cada paso temporal t , la red recurrente (LSTM) recibe como entrada el valor observado $z_{i,t-1}$ (o muestras de la distribución predictiva durante la fase de generación) y el vector de covariables $\mathbf{x}_{i,t}$. El estado oculto resultante $\mathbf{h}_{i,t}$ es proyectado a los parámetros de la distribución de salida elegida:

$$\mathbf{h}_{i,t} = \text{LSTM}(\mathbf{h}_{i,t-1}, [z_{i,t-1}, \mathbf{x}_{i,t}, \mathbf{e}_i]) \quad (5)$$

donde $\mathbf{e}_i$ es el embedding estático de la serie i , que encapsula características fijas como categoría, tienda y producto.

Como propuesta de innovación arquitectónica y con el objetivo de mitigar problemas de convergencia estocástica, los pesos de las capas densas de proyección y de la red recurrente fueron condicionados mediante la *inicialización de He* (o Kaiming). Esta técnica adapta la varianza de los pesos iniciales en función de la dimensión de entrada de la capa, garantizando que la magnitud de las activaciones y de los gradientes se mantenga estable a lo largo de las tres capas ocultas apiladas, previniendo así patologías numéricas durante los primeros pasos del entrenamiento.

6.2. Distribución de salida: Binomial Negativa

La distribución de salida elegida fue la **Binomial Negativa**, parametrizada por su media μ y el parámetro de dispersión α (o equivalentemente $r = 1/\alpha$):

$$P(Y = k \mid \mu, \alpha) = \frac{\Gamma(k + 1/\alpha)}{\Gamma(1/\alpha) k!} \left(\frac{1/\alpha}{1/\alpha + \mu} \right)^{1/\alpha} \left(\frac{\mu}{1/\alpha + \mu} \right)^k, \quad k \in \mathbb{Z}_{\geq 0} \quad (6)$$

La media y la varianza de esta distribución son:

$$\mathbb{E}[Y] = \mu \quad (7)$$

$$\text{Var}[Y] = \mu + \alpha \mu^2 \quad (8)$$

Con el contexto previo del documento, la distribución Binomial Negativa es adecuada para el modelado de este problema porque:

1. Genera valores enteros no negativos, consistentes con datos de conteo de ventas.
2. Permite varianza $>$ media (acode a la sobredispersión del dataset), lo cual es común en la industria de demanda minorista.
3. Maneja apropiadamente la presencia de ceros ya que es parte natural de la distribución.

6.3. Configuración experimental

La configuración final del modelo fue:

```
DeepAREstimator(  
    freq                = "D",  
    prediction_length    = 28,  
    context_length       = 84,      # 3 x prediction_length  
    num_layers           = 3,  
    hidden_size          = 80,  
    dropout_rate         = 0.1,  
    distr_output         = NegativeBinomialOutput(),  
    batch_size           = 128,  
    num_batches_per_epoch = 300,  
    lr                   = 5e-4,  
    max_epochs           = 40  
)
```

Listing 1: Configuración del estimador DeepAR.

Algunos aspectos a destacar de esta configuración:

- **context_length = 84**: el modelo observa 84 días de historia (3 veces el horizonte de predicción) para generar el pronóstico. Esto permite capturar estacionalidad semanal (ciclos de 7 días) en múltiples semanas.
- **num_layers = 3**: tres capas LSTM apiladas permiten representar patrones jerárquicos en la serie temporal.

- **dropout_rate = 0.1**: regularización para reducir sobreajuste dado el tamaño del modelo.
- **lr = 5e-4**: tasa de aprendizaje con optimizador Adam.

6.4. Infraestructura de entrenamiento

El entrenamiento se realizó en el entorno de **Google Colab** usando la GPU NVIDIA T4 que nos proporciona la versión gratuita. El tiempo aproximado de entrenamiento fue de **31 minutos** para 40 épocas sobre las 12 196 series.

Durante el entrenamiento, el modelo optimiza la log-verosimilitud negativa de la distribución de salida:

$$\mathcal{L}(\theta) = - \sum_{i=1}^N \sum_{t \in \Omega_{\text{train}}} \log P_{\theta}(y_{i,t} \mid y_{i,1:t-1}, \mathbf{x}_{i,1:t}) \quad (9)$$

donde Ω_{train} denota el conjunto de pasos temporales de entrenamiento.

Para diagnosticar la estabilidad numérica del modelo durante la optimización estocástica y asegurar un correcto flujo de aprendizaje, se monitoreó la evolución de la norma L2 de los gradientes por capa durante las primeras iteraciones sobre el conjunto de validación (véase la Figura 3). El comportamiento observado valida que no se presentaron patologías de desvanecimiento (*vanishing*) ni explosión (*exploding*) de gradientes en las capas de la red recurrente.




Figura 3: Evolución de la Norma L2 de los gradientes por capa durante las primeras iteraciones del entrenamiento. Se observa la estabilidad y convergencia del flujo de gradientes.

7. Resultados

7.1. Comparación de modelos

La Tabla 5 muestra el desempeño comparativo de los cuatro modelos evaluados sobre el conjunto definitivo de prueba o test (últimos 28 días aislados de cada serie histórica).

Cuadro 5: Comparación de modelos: métricas de error en el conjunto de prueba (Test).

Modelo	MAE	RMSE	sMAPE	Bias
Naive último valor	1.4794	3.4521	0.8541	0.2698
Seasonal Naive 28 días	1.3416	2.9028	0.8428	-0.0286
Moving Average 28 días	1.1070	2.2604	1.2616	-0.0286
DeepAR Neg. Binomial	0.9942	2.2612	0.6972	-0.4421

7.2. Análisis de métricas

MAE (Mean Absolute Error): DeepAR obtuvo un MAE de 0,9942 en la fase de prueba, reduciéndolo en un 10,2 % respecto al mejor baseline (Moving Average, 1,1070). Dado que la venta media es 1,23 unidades, esta mejora es relevante en términos relativos y demuestra la generalización en datos no vistos.

RMSE (Root Mean Squared Error): DeepAR logró un RMSE de 2,2612, un desempeño competitivo y muy cercano al benchmark del Moving Average (2,2604). El RMSE penaliza más los errores grandes, reflejando que el promedio móvil sigue siendo robusto para series estables, mientras que la aproximación de DeepAR contiene errores dispersos similares bajo la nueva evaluación del Test.

sMAPE (Symmetric Mean Absolute Percentage Error): DeepAR obtuvo el sMAPE más bajo (0,6972), superando significativamente al Moving Average (1,2616). El sMAPE alto del promedio móvil se explica porque, en series con ventas cercanas a cero, pequeños errores absolutos generan grandes errores porcentuales.

Bias: El bias de DeepAR en el test fue de $-0,4421$, indicando una leve *subestimación sistemática* de la demanda. Los modelos Seasonal Naive y Moving Average presentan un bias cercano a cero, mientras que el Naive último valor tiene bias positivo (sobreestimación).




Figura 4: Comparación de modelos según RMSE. DeepAR obtiene un RMSE competitivo ante el test, mostrando diferencias moderadas con el promedio móvil de 28 días.

8. Evaluación Probabilística

Una ventaja clave de DeepAR sobre los modelos tradicionales o base es su capacidad de generar *distribuciones* en lugar de únicamente predicciones puntuales de las ventas de los productos. A partir de muestras de la distribución posterior, se calcularon cuantiles y los intervalos de predicción.

8.1. Pérdida cuantílica

La pérdida cuantílica (*Quantile Loss*, QL) para el nivel q se define como:

$$QL_q = \frac{2}{n} \sum_{i=1}^n [q \cdot \max(y_i - \hat{q}_i, 0) + (1 - q) \cdot \max(\hat{q}_i - y_i, 0)] \quad (10)$$

Cuadro 6: Métricas probabilísticas de DeepAR.

Métrica	Valor
QL 0.5 (mediana)	0.4975
QL 0.9 (cuantil superior)	0.3334
Cobertura intervalo 80 %	0.9090

8.2. Análisis de cobertura

La cobertura del intervalo del 80 % fue de **90.9 %**, superando el nivel del 80 %. Esto indica que el modelo es algo conservador en sus predicciones: sus intervalos de predicción son más amplios de lo que se quisiera, capturando más observaciones reales que las esperadas.

La sobrecobertura puede deberse a:

1. El parámetro de dispersión α de la Binomial Negativa puede estar sobreestimando la variabilidad de las series.
2. El modelo no está perfectamente calibrado respecto a la distribución empírica.
3. La heterogeneidad entre series hace difícil calibrar un único modelo global para todos los niveles de demanda.




Figura 5: Pronóstico probabilístico para una serie de alta demanda. La línea azul muestra la historia real, la línea naranja el forecast y el área sombreada el intervalo predictivo al 80 %. El modelo captura la dinámica general aunque tiende a suavizar los picos de demanda.

9. Diagnóstico de Predicciones Extremas

9.1. Problema inicial

Durante el desarrollo, una versión preliminar del modelo generaba predicciones extremas del orden de 10^5 unidades, claramente inconsistentes con el rango histórico reportado o comparado. La causa raíz fue el tratamiento incorrecto de las covariables temporales: al codificarlas como enteros sin normalizar, la red interpretaba valores como “día 300” o “día 1913” como señales de gran magnitud, distorsionando las activaciones de la LSTM.

9.2. Resultados tras la corrección

Después de normalizar las covariables temporales al rango $[0, 1]$, las predicciones se estabilizaron. La Tabla 7 muestra los valores máximos comparativos:

Cuadro 7: Valores extremos: predicción vs. real.

Métrica	Valor
Predicción máxima DeepAR	150
Real máximo	204
Error absoluto máximo	102

Cuadro 8: Distribución de percentiles: predicción DeepAR vs. valores reales.

Percentil	Predicción DeepAR	Real
50 %	0	0
75 %	1	2
90 %	3	4
95 %	4	6
99 %	11	15
99.5 %	15	21
99.9 %	31	41
100 %	150	204

9.3. Subestimación en la cola

La Tabla 8 muestra un patrón que persiste: a partir del percentil 75, las predicciones de DeepAR son en general menores que los valores reales. En el percentil 99.9, el modelo predice 31 unidades mientras que la demanda real fue de 41 (una subestimación del $\sim 24\%$). Esto refleja que el modelo aprende bien el comportamiento típico de las series, pero tiende a subestimar la cola superior de la distribución.

Esta es habitual en modelos globales entrenados con muchas series de demanda baja: la función de pérdida penaliza igualmente todos los errores, por lo que el modelo tiende a optimizar el desempeño en la masa central de la distribución, a costa de los cuantiles extremos.

10. Discusión

Los resultados obtenidos son satisfactorios para una primera réplica del modelo y paper que se propone con DeepAR sobre el challenge M5 para el universo acotado de California. El modelo superó a los tres benchmarks en MAE y sMAPE, y obtuvo un RMSE sumamente competitivo frente al promedio móvil de 28 días en la partición final de prueba.

Ventajas del enfoque global. DeepAR aprovecha la transferencia de información entre las 12 196 series. Esto es especialmente valioso para series con demanda intermitente, donde el historial individual es poco informativo. El modelo puede aprender, por ejemplo, que los patrones de venta de un producto nuevo en una tienda son similares a los de productos similares en otras tiendas.

Limitación: subestimación del bias. El bias negativo ($-0,4421$) indica una subestimación sistemática. Esto puede corregirse mediante:

- Ajuste del umbral de predicción (predicción condicional en cuantiles superiores).
- Incorporación de precios y eventos como covariables, que son predictores de picos de demanda.
- Post-procesamiento de las predicciones mediante escalado por factor de corrección de bias.

Limitación: intervalos conservadores. La cobertura del 90.9 % para un intervalo nominal del 80 % indica que los intervalos son demasiado amplios. Esto reduce la utilidad práctica del modelo para gestión de inventario, donde intervalos muy amplios impiden decisiones de stock precisas. Se recomienda aplicar calibración de cuantiles post-entrenamiento, como *conformal prediction* o escalado de temperatura.

11. Limitaciones

Las principales limitaciones del presente proyecto son:

1. **Subconjunto geográfico:** se trabajó únicamente con California y no con el dataset M5 completo (tres estados). Esto reduce la generalización del modelo y no permite comparación directa con los resultados oficiales de la competencia. Esto se realizó de esta manera debido a que el data set directo del paper no se encontraba disponible para el público y de igual manera los recursos computacionales no permitían el uso de todo el dataset y es por eso que se hizo la acotación del universo
2. **Sin covariables de precio:** el campo `sell_price` no fue incorporado como covariable dinámica, lo cual es una omisión importante dado el efecto de las promociones y descuentos sobre la demanda.
3. **Sin eventos del calendario:** los eventos especiales (festivos nacionales, fiestas deportivas, eventos locales) no se incorporaron en esta versión. Estos eventos tienen impacto documentado en las ventas de retail.
4. **Métrica de evaluación:** no se evaluó con WRMSSE (*Weighted Root Mean Squared Scaled Error*), que es la métrica oficial del challenge M5 y pondera la importancia de cada serie según su volumen de ventas.
5. **Subestimación en alta demanda:** el modelo presenta una tendencia a subestimar la demanda en productos con ventas elevadas o picos importantes.
6. **Intervalos probabilísticos conservadores:** los intervalos predictivos cubren más del nivel nominal, reduciendo su utilidad operativa.

12. Trabajo Futuro

Para mejorar y extender el modelo se recomienda:

1. **Incorporar precios:** incluir `sell_price` como covariable dinámica, posiblemente junto con indicadores de descuento o variación de precio respecto a la semana anterior.
2. **Agregar eventos y promociones:** codificar los eventos del calendario M5 (“SNAP”, festivos, eventos deportivos) como variables binarias o embeddings categóricos.
3. **Entrenar sobre todo M5:** extender el entrenamiento a los tres estados para aprovechar mejor la capacidad de generalización del modelo global y permitir comparación con la literatura.
4. **Comparar contra modelos más fuertes:** evaluar LightGBM con features de lagged values, N-BEATS [Oreshkin et al., 2020] y Temporal Fusion Transformer [Lim et al., 2021], que son los modelos de mejor desempeño en M5.
5. **Evaluar con WRMSSE:** implementar la métrica oficial de M5 para obtener resultados comparables con los reportados en la competencia.
6. **Explorar contextos temporales más largos:** probar `context_length` de 112 o 168 días para capturar ciclos de 4 y 6 semanas respectivamente.
7. **Calibración probabilística:** aplicar técnicas de calibración de cuantiles post-entrenamiento (por ejemplo, *conformal prediction*) para reducir la amplitud excesiva de los intervalos predictivos.

13. Conclusiones

En este proyecto se replicó exitosamente la idea central de DeepAR [Salinas et al., 2020] sobre el subconjunto California del dataset M5 Forecasting.

Los principales hallazgos son:

1. **DeepAR superó a los tres benchmarks** en MAE (0.9942 vs. 1.1070) y sMAPE (0.6972 vs. 0.8428) bajo la evaluación estricta de la partición de prueba, manteniendo un RMSE robusto y competitivo. Esto confirma que el entrenamiento global sobre múltiples series relacionadas aporta valor frente a métodos simples de forecasting.
2. **La distribución Binomial Negativa** fue una elección adecuada para los datos de M5, dados los altos porcentajes de ceros ($\sim 66\%$) y la fuerte sobredispersión observadas en el análisis exploratorio.
3. **La normalización de covariables temporales** fue un punto crítico del desarrollo. Sin normalización, el modelo generaba predicciones absurdas. Con normalización al rango $[0, 1]$, las predicciones se estabilizaron de inmediato, resaltando la importancia del preprocesamiento en modelos de aprendizaje profundo.
4. **La evaluación probabilística** mostró que DeepAR genera intervalos conservadores (cobertura 90.9 % para nivel nominal 80 %), lo que indica espacio de mejora en la calibración de la distribución predictiva.
5. **Existe subestimación en la cola superior**, donde el modelo predice consistentemente menos que los valores reales en los percentiles 75–99.9. Esto es un efecto típico de modelos globales entrenados con mayoría de series de demanda baja.

A pesar de estas limitaciones, los resultados obtenidos constituyen una base sólida para futuras iteraciones. Las mejoras más prometedoras involucran la incorporación de precios y eventos del calendario como covariables, la calibración de cuantiles post-entrenamiento y la evaluación formal con la métrica WRMSSE sobre el dataset M5 completo.

14. Análisis de Resultados y Conclusiones

A continuación, se presenta el análisis crítico y la reflexión teórica sobre el proceso de réplica del modelo DeepAR aplicado al conjunto de datos M5, respondiendo de manera sistemática a los ejes de evaluación requeridos:

¿Se logró reproducir el modelo propuesto y los resultados obtenidos en el estudio seleccionados?

Sí se logró reproducir la metodología general del modelo y sus resultados esenciales dentro de las limitaciones metodológicas ya mencionadas. Esta réplica empírica demostró la efectividad del enfoque probabilístico, alcanzando un comportamiento consistente a pesar de las discrepancias impuestas por el uso de un subconjunto de datos y la capacidad de los recursos computacionales a disposición.

¿Qué dificultades se enfrentaron al implementar el modelo original?

La principal dificultad enfrentada radicó en la falta de acceso al dataset original exactamente como fue configurado por los autores, sumado a las restricciones de los recursos computacionales disponibles para el entrenamiento a gran escala. Estos factores obligaron a realizar modificaciones estratégicas en el alcance del proyecto, orientando el desarrollo hacia el subconjunto de California distribuyendo los datos en bloques secuenciales de entrenamiento, validación y prueba con el objetivo de mantener la consistencia metodológica.

¿Qué diferencias encontraron en la implementación?

Dentro de nuestra propuesta, incorporamos técnicas no detalladas en el artículo original, tales como regularización por *dropout* e inicialización de pesos de He, buscando innovar en la arquitectura con base en el contenido visto en clase para obtener un mejor rendimiento. Asimismo, se optó por aislar un conjunto explícito de validación para sintonizar los hiperparámetros y registrar la pérdida junto al comportamiento de gradientes antes de ejecutar la inferencia de prueba final.

¿Existe información faltante en el artículo, que sea necesaria para lograr una implementación completa?

No se detectaron omisiones críticas en la descripción matemática de la arquitectura ni en la formulación de la distribución de salida; sin embargo, la principal limitante de información para una réplica exacta fue la falta de disponibilidad del dataset original y su pipeline de preprocesamiento específico, además de los criterios exactos para la separación secundaria de los conjuntos internos de control del entrenamiento.

¿Existen diferencias en los resultados obtenidos en comparación con los resultados obtenidos en el estudio original?

No es posible afirmar de manera categórica la existencia de diferencias cuantitativas precisas debido a que la disposición del dataset original no estaba disponible para realizar un contraste directo. A pesar de esto, a nivel cualitativo, los resultados

medidos en el test de generalización son satisfactorios, ya que muestran un comportamiento predictivo y una captura de la incertidumbre análogos a las tendencias reportadas por los autores.

¿Qué técnica(s) aplicaste para la correcta identificación de fallas (ej., desvanecimiento/ex

Para identificar y mitigar patologías algorítmicas durante la optimización estocástica, se implementó la división del conjunto de validación para el monitoreo activo de la norma L2 de los gradientes por capa en los primeros pasos del entrenamiento, verificando un flujo de gradientes estable. Adicionalmente, el análisis predictivo de las curvas de función de pérdida (*Train* vs. *Val Loss*) y el seguimiento de las métricas de desempeño permitieron evaluar el comportamiento de la red y diagnosticar oportunamente posibles problemas de sobreajuste o inestabilidad numérica.

¿Estás de acuerdo en la arquitectura propuesta por el artículo seleccionado?

Sí, estoy de acuerdo con la arquitectura propuesta: el enfoque global basado en redes recurrentes demostró ser altamente efectivo para transferir conocimiento estadístico entre series del dataset M5, superando a los métodos tradicionales en métricas como MAE y sMAPE, mientras que la distribución Binomial Negativa resultó fundamental para modelar la intermitencia y sobredispersión de la demanda sin recurrir a transformaciones artificiales.

¿Qué cambiarías en la arquitectura del modelo para mejorar su desempeño?

Se podría sustituir la red LSTM original por una arquitectura GRU (*Gated Recurrent Unit*); al unificar los estados ocultos y de celda en un solo vector y reducir el mecanismo a dos compuertas (actualización y restablecimiento), la GRU simplifica la complejidad estructural y disminuye significativamente los tiempos de cómputo en la GPU, actuando además como un regularizador natural que mitiga el sobreajuste en series con alta proporción de ceros.

Referencias

- Salinas, D., Flunkert, V., Gasthaus, J., & Januschowski, T. (2020). DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks. *International Journal of Forecasting*, 36(3), 1181–1191. <https://doi.org/10.1016/j.ijforecast.2019.07.001>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 Accuracy Competition: Results, Findings, and Conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>
- Oreshkin, B. N., Carпов, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/1905.10437>
- Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting. *International Journal of Forecasting*, 37(4), 1748–1764. <https://doi.org/10.1016/j.ijforecast.2021.03.012>